

Synergy-Aware Pokémon Team Recommendation Using Fine-Tuned Small Language Models with Retrieval-Augmented Generation



Written by:

2702210232 - Stanley Jonathan Wahjudi

2702218891 - Ian Mulya Chiuandi

2702307972 - Jonathan

BINUS University

2025

BAB I: PENDAHULUAN

1.1 Latar Belakang

Pokémon adalah sebuah game yang diproduksi oleh GameFreak dan dipublish oleh Nintendo. Secara standarnya, Pokémon merupakan sebuah game *turn-based* dimana user dapat membangun satu tim Pokémon dengan enam anggota Pokémon, dimana Pokémon akan dikeluarkan satu per satu dalam pertarungan. Karena kepopuleran game Pokémon, cukup banyak turnamen yang diselenggarakan untuk bertarung dengan Pokémon. Dari sinilah, konsep Competitive Pokémon Battling, diselenggarakan dalam berbagai jenis event-event, contohnya Video Game Championships (VGC). Sebagai format standar dalam turnamen internasional, VGC menerapkan sistem *Doubles Battle* yang mengharuskan setiap pemain untuk mengoperasikan dua Pokémon secara bersamaan di medan tempur.

Penggunaan format *Doubles* dalam VGC menciptakan ruang status (*state space*) yang jauh lebih luas dibandingkan format tunggal, karena melibatkan interaksi antar-agen, sinergi kemampuan, dan manajemen risiko terhadap variabel probabilitas yang inheren dalam permainan. Dalam konteks penelitian ini, VGC dipandang sebagai sebuah lingkungan stokastik dengan informasi yang tidak lengkap, di mana setiap keputusan taktis dipengaruhi oleh prediksi terhadap pergerakan lawan dan pemahaman mendalam tentang mekanik permainan. Kompleksitas inilah yang menjadi landasan bagi eksplorasi penggunaan *Small Language Models* (SLM) sebagai agen cerdas yang diharapkan mampu memproses data numerik tim yang digunakan dalam turnamen VGC Region H 2025 secara efisien untuk menghasilkan tim dengan sinergi yang optimal.

1.1.1 Perkembangan Small Language Models

Perkembangan Small Language Models (SLM) telah menunjukkan bahwa ukuran model yang lebih kecil tidak selalu berkorelasi dengan performa yang lebih rendah. Microsoft memperkenalkan keluarga model Phi-3, yang mendemonstrasikan bahwa model dengan 3.8 miliar parameter dapat menyaingi performa model yang jauh lebih besar seperti Mixtral 8x7B dan GPT-3.5 (Abdin et al., 2024). Phi-3-Instruct-4K mencapai skor 69% pada benchmark MMLU (Massive Multitask Language Understanding) dan 8.38 pada MT-bench, meskipun cukup kecil untuk dapat dijalankan pada perangkat mobile. Inovasi utama terletak pada pendekatan kualitas data pelatihan yang sangat selektif, menggunakan kombinasi data web

yang telah difilter secara ketat dan data sintetis, bukan sekadar mengandalkan kuantitas data yang besar.

Model Phi-3 juga menjalani proses post-training yang mencakup supervised fine-tuning dan direct preference optimization untuk meningkatkan kemampuan instruction-following dan langkah-langkah keamanan (Abdin et al., 2024). Pendekatan ini sangat relevan dengan penelitian kami karena menunjukkan bahwa SLM dapat diadaptasi untuk domain-specific tasks melalui fine-tuning yang terstruktur dengan data berkualitas tinggi.

1.1.2 Parameter-Efficient Fine-Tuning dengan QLoRA

Untuk mengatasi keterbatasan komputasi dalam fine-tuning model bahasa, Dettmers et al. (2023) memperkenalkan QLoRA (Quantized Low-Rank Adaptation), sebuah metode yang memungkinkan fine-tuning model besar menggunakan GPU tunggal sambil mempertahankan 99% performa model full precision. QLoRA menggunakan kuantisasi 4-bit dengan tipe data NF4 (Normal Float 4) yang mengasumsikan distribusi normal pada weight model, serta menerapkan double quantization pada scaling factors untuk lebih menghemat memori.

Teknik ini sangat sesuai dengan konteks penelitian kami yang memiliki keterbatasan waktu dan resource komputasi. Hu et al. (2021) menunjukkan bahwa low-rank adaptation dapat mencapai performa yang sebanding dengan full fine-tuning pada berbagai downstream tasks sambil hanya melatih 0.01% dari total parameters. Penelitian ini juga mendemonstrasikan bahwa LoRA sangat efektif untuk domain adaptation, terutama ketika domain target memiliki istilah yang berbeda dari pre-training data, seperti dalam data Pokemon.

1.1.3 Retrieval-Augmented Generation untuk Tugas Berbasis Pengetahuan

Retrieval-Augmented Generation (RAG) telah terbukti efektif untuk tugas-tugas yang memerlukan akses ke pengetahuan faktual yang luas. Lewis et al. (2020) menunjukkan bahwa RAG dapat meningkatkan factual accuracy model bahasa dengan menggabungkan retrieval dari knowledge base eksternal dengan generasi teks. Pendekatan ini sangat relevan karena Phi-3-Instruct-4K, meskipun berkinerja sangat baik dalam reasoning, memiliki keterbatasan

dalam menyimpan konteks yang kecil, seperti terlihat dari performa yang lebih rendah pada benchmark TriviaQA (Abdin et al., 2024).

Dalam konteks game strategis seperti Pokémon VGC, pendekatan RAG sangat sesuai karena kebutuhan untuk mengakses informasi spesifik tentang mekanik permainan, statistik Pokémon, dan matchup data. Model perlu tidak hanya memahami prinsip-prinsip team-building, tetapi juga dapat mengakses dan mengintegrasikan data terstruktur tentang atribut Pokémon, effectiveness types, dan usage statistics dari meta kompetitif yang terus berkembang.

1.1.4 Penelitian LLM untuk Pokémon Battling

Dalam beberapa tahun terakhir, terdapat minat penelitian yang meningkat dalam menggunakan Large Language Models untuk pertarungan Pokémon kompetitif, yang menghadirkan tantangan unik dalam reasoning strategis dan pengambilan keputusan dalam lingkungan yang kompleks dan stokastik. Hu et al. (2024) memperkenalkan PokéLLMon, sebuah benchmark untuk mengevaluasi kemampuan grounding dan reasoning LLM dalam pertarungan Pokémon. Penelitian mereka mendemonstrasikan bahwa meskipun LLM memiliki kemampuan reasoning yang kuat, mereka mengalami kesulitan signifikan dalam pertarungan Pokémon karena kurangnya pengetahuan domain-specific tentang mekanik permainan. PokéLLMon menggunakan teknik prompting dan self-consistency untuk menghasilkan keputusan battle, namun masih menunjukkan keterbatasan dalam memahami interaksi kompleks antara tipe Pokémon, abilities, dan strategic matchups. Karten et al. (2025) mengembangkan PokéChamp, sebuah minimax agent yang memanfaatkan LLM untuk meningkatkan tree search dalam pertarungan Pokémon kompetitif. Berbeda dengan pendekatan reinforcement learning yang memerlukan training ekstensif, PokéChamp tidak memerlukan training tambahan dan mencapai Elo rating 1300-1500 pada Pokémon Showdown, menempatkannya dalam top 10-30% pemain manusia. Sistem ini menggunakan LLM untuk tiga komponen kunci: action sampling, opponent modeling, dan value function estimation. Ketika dipasangkan dengan GPT-4o, PokéChamp mencapai win rate 76% melawan bot berbasis LLM terbaik sebelumnya dan 84% melawan rule-based bot terkuat. Yang menarik, bahkan dengan model open-source Llama 3.1 8B parameter, PokéChamp masih mengungguli PokéLLMon yang menggunakan GPT-4o, menunjukkan bahwa arsitektur dan pendekatan strategis lebih penting daripada ukuran model semata. Yashwanth dan Dhatri (2025) memperkenalkan LLM Pokémon League, sebuah sistem yang menggunakan

pertarungan Pokémon kompetitif untuk mempelajari bagaimana LLM melakukan reasoning dan membuat keputusan strategis. Sistem ini memfasilitasi turnamen di mana model-model dari OpenAI, Anthropic, dan Google bertarung satu sama lain, dengan setiap tindakan dijelaskan dalam bahasa natural untuk memungkinkan analisis mendalam terhadap proses berpikir model. Penelitian ini mengungkapkan perbedaan yang jelas dalam bagaimana berbagai model mendekati pertarungan, dari careful team balance hingga risk-heavy play styles, memberikan wawasan tentang kemampuan strategis model-model terkemuka saat ini. Perbedaan fundamental antara penelitian-penelitian tentang Pokémon battling dan penelitian kami terletak pada fokus aplikasi. Penelitian-penelitian tersebut fokus pada tactical decision-making selama pertarungan (battle mechanics), sementara penelitian kami fokus pada strategic team-building sebelum pertarungan dimulai. Team-building memerlukan pemahaman holistik tentang synergies, role distribution, dan defensive coverage yang berbeda dari keputusan turn-by-turn dalam pertarungan. Selain itu, penelitian-penelitian sebelumnya menggunakan LLM berukuran besar (GPT-4o, Claude) atau tidak melakukan fine-tuning sama sekali, sementara kami mengeksplorasi supervised dan preference fine-tuning pada SLM untuk adaptasi domain yang lebih efisien.

1.1.5 Kesenjangan Penelitian

Akan tetapi, model SLM tidak bisa digunakan secara langsung untuk membangun tim Pokémon karena SLM tidak memiliki pengetahuan domain Pokémon, sehingga SLM tidak mengerti cara kerja game, mengeluarkan hasil yang tidak relevan terhadap taktik paling efektif dan lemah dalam mengintegrasikan data berstruktur (contohnya penggunaan, atribut, dan counter terhadap Pokémon lain). Meskipun penelitian-penelitian sebelumnya telah mendemonstrasikan efektivitas SLM dalam berbagai domain dan teknik-teknik fine-tuning yang efisien, belum ada penelitian yang secara komprehensif menggabungkan fine-tuning SLM dengan RAG untuk tugas team-building Pokémon yang strategy-aware.

Oleh karena itu, kami memutuskan untuk melakukan supervised fine-tuning dan preference fine-tuning sebuah SLM, untuk membaca data terstruktur berisi data Pokémon; dalam upaya untuk merekomendasikan tim Pokemon yang layak digunakan dalam kompetisi VGC reg H format. Beberapa permasalahan yang mungkin muncul dalam upaya ini adalah bagaimana SLM dapat menggabungkan terminologi game-specific, strategi kompetitif, nuansa dari team-building, dan data statistik beserta data matchup antara Pokémon.

Solusi yang kami sadari adalah untuk membangun sebuah domain-specific fine-tuned SLM chatbot pada dataset Pokémon sintetis dengan kapabilitas RAG untuk menghasilkan output berupa rekomendasi mendalam terhadap team-building Pokémon yang akan di-deploy sebagai sebuah web app bernama PokéGuide. Alhasil, PokéGuide dapat menghasilkan rekomendasi tim yang kohesif dan layak dengan strategi yang masuk akal, berserta berfungsi sebagai alat penelitian untuk mempelajari pengambilan keputusan yang dibantu AI dalam sebuah permainan; menjembatani kesenjangan antara wawasan berbasis data dan intuisi strategi manusia.

1.2 Tujuan

1.2.1 Meningkatkan Performa Model SLM Untuk Membangun Tim Pokémon Bersifat Strategy-Aware

Kami berharap model SLM yang kami fine-tune dapat memberikan performa yang baik ketika diminta membangun tim pokémon. Dalam hal ini, kami berharap agar tim pokémon yang dibuat oleh model SLM memiliki sinergi, komposisi, dan kekuatan yang baik dalam kondisi turnamen pokémon.

1.2.2 Menghasilkan Pipeline Fine Tuning SLM yang Efisien dan Efektif Untuk Adaptasi Domain SLM

Kami berharap proses fine tuning SLM untuk adaptasi domain pokémon dapat memberikan insight baru tentang proses adaptasi domain lainnya pada model SLM dengan metode fine tuning. Hasil pipeline fine tuning SLM yang didokumentasikan dapat diaplikasikan adaptasi domain lainnya pada model SLM modern secara general.

1.2.3 Menganalisis Bagaimana SLM Memahami Domain yang Diadaptasi Melalui Q-LoRA

Kami berharap dengan adanya evaluasi yang mendalam mengenai statistik performa, analisis kekurangan, dan pola tertentu yang muncul pada SLM yang sudah dilatih. Hal ini dapat membuka pola-pola yang ada dalam adaptasi domain SLM.

1.3 Ruang Lingkup

Eksperimen ini mencakup 3 tahapan utama, yaitu pembuatan dataset, pemodelan, dan evaluasi.

1.3.1 Pembuatan Dataset

Dataset yang digunakan dalam eksperimen ini merupakan dataset buatan sendiri melalui metode scraping dan modifikasi manual. Konten dataset utama diambil dari forum-forum kompetisi Pokémon tentang strategi setiap Pokémon (Bulbapedia, Smogon). Kami melakukan modifikasi berupa pembuatan struktur strategi dan atribut setiap Pokémon dalam file JSON yang lebih rapi dan lebih mudah digunakan untuk modeling, seperti prompt creation.

Dataset yang sudah terstruktur kemudian digunakan untuk pembuatan prompt dan output strategi sebagai dataset pemodelan utama. Dataset ini yang membantu model SLM aware terhadap domain strategi Pokémon dan pembuatan tim. Pembuatan prompt dilakukan menggunakan model LLM.

1.3.2 Pemodelan

Model SLM tidak dibuat dan dilatih dari scratch, melainkan model SLM dilatih menggunakan metode PEFT (Parameter-Efficient Fine Tuning), yaitu Q-LoRA. Pilihan penggunaan Q-LoRA disesuaikan dengan batasan waktu dan resource. Q-LoRA menambahkan adapter berupa dua matriks, yaitu matriks A dan B di mana weightnya berupa tipe data NF4 (Normal Float 4). NF4 merupakan tipe data 4 bit yang mengasumsikan distribusi normal dengan menggunakan formula kuantil yang terbagi dalam distribusi normal. Penggunaan NF4 dapat menurunkan performa karena weight outlier dianggap tidak akan pernah muncul. Maka dari itu, Selain itu, Q-LoRA juga menggunakan double quantization, dimana ada kuantisasi pada scaling factor quantization sehingga mengurangi ukuran dan resource yang dibutuhkan.

1.3.3 Evaluasi

Untuk menguji kapabilitas dan efektivitas chatbot yang dikembangkan, penelitian ini menggunakan sejumlah sampel representatif dari dataset sebagai **titik acuan (benchmark)**

ideal. Sampel tersebut mencakup parameter kualitas tim serta argumen logis mengenai efektivitas strategi, yang berfungsi sebagai standar emas (*gold standard*) untuk mengevaluasi ketepatan respons model.

Kualitas tim dievaluasi berdasarkan distribusi peran setiap Pokémon dalam tim serta sinergi strategis yang tercipta dari keseimbangan antara kekuatan ofensif dan cakupan pertahanan (*defensive coverage*). Evaluasi ini memastikan bahwa setiap anggota tim memiliki fungsi spesifik yang saling melengkapi guna memitigasi kelemahan individual terhadap berbagai ancaman dalam meta-permainan VGC.

BAB II: DATASET

2.1 Data Exploration

Dataset dalam penelitian ini disusun secara mandiri melalui ekstraksi data (*web scraping*) dari dua sumber otoritatif dalam komunitas Pokémon, yaitu PokeAPI dan Smogon University. Data yang diperoleh ditransformasikan ke dalam format JSON terstruktur yang mencakup parameter krusial untuk analisis strategis, meliputi frekuensi penggunaan (*usage statistics*), konfigurasi set optimal (*optimal builds*), serta rekomendasi sinergi antar-entitas (*recommended teammates*). Konstruksi dataset ini bertujuan untuk menyediakan representasi komprehensif mengenai dinamika meta-permainan terkini, yang berfungsi sebagai instrumen fundamental dalam fase pelatihan dan evaluasi model.

2.2 Eksplorasi Dataset

Setiap entri dalam dataset dirancang untuk memfasilitasi pembelajaran berbasis instruksi (*instruction tuning*), yang terdiri dari identitas Pokémon, instruksi kontekstual, dan output terstruktur yang mencakup delapan dimensi analisis berikut:

- *Short Summary*: Ringkasan singkat profil strategis.
- *Full Analysis*: Analisis mendalam mengenai kapabilitas unit.
- *Matchup Overview*: Evaluasi interaksi terhadap entitas lawan.
- *Role Description*: Klasifikasi peran operasional dalam tim.
- *Synergy Breakdown*: Penjelasan mengenai mekanisme integrasi antar-agen.
- *Recommended Sets*: Spesifikasi teknis meliputi *moveset*, *item*, dan distribusi statistik.
- *Weaknesses & Counters*: Identifikasi kerentanan dan ancaman spesifik.
- *Sample Team Concept*: Prototipe komposisi tim yang kohesif.

Data mentah (*raw data*) tersebut melalui tahap pemrosesan awal (*preprocessing*) dan augmentasi data menggunakan model Kimi-K2 untuk menghasilkan lebih dari 2.200 pasang input-output sintesis serta 800 catatan statistik mengenai keunggulan kompetitif setiap Pokémon. Setiap entri pelatihan dikonstruksi dengan skema *field-based* yang menghubungkan input pengguna dengan output yang kaya akan konteks. Struktur ini dirancang secara optimal untuk melakukan *fine-tuning* pada Small Language Models (SLM), guna menghasilkan model yang tidak hanya akurat secara faktual, namun juga memiliki

kesadaran strategi (*strategy-aware*) dalam merumuskan rekomendasi pembentukan tim kompetitif. Berikut adalah representasi formal dari entri dataset yang digunakan:

```
[
  {
    "pokemon": "Gholdengo",
    "input": "Write a detailed
'short_summary' section using only the data
given.\n\n<DATA>{\n\"Gholdengo\":
{\n\"Abilities\": {\n\"goodasgold\":
2150.0674341869494}, \n\"Items\":
{\n\"lifeorb\": 0.40078689096573855,
\n\"choicespecs\": 0.283475718438179},
\n\"Spreads\": {\n\"Modest:4/0/0/252/0/252\":
0.1762777004844856}, \n\"Moves\":
[\n\"makeitrain\", \n\"shadowball\",
\n\"nastyplot\", \n\"protect\"], \n\"Tera Types\":
{\n\"water\": 0.37287903306152614, \n\"steel\":
0.45402448761654873}, \n\"Teammates\":
[\n\"Incineroar\", \n\"Archaludon\",
\n\"Sneasler\", \n\"Rillaboom\", \n\"Dragonite\",
\n\"Ursaluna-Bloodmoon\"]}}</DATA>",
    "output": "<OUTPUT>Gholdengo is a
premier special attacker in VGC, leveraging
its signature ability Good as Gold—an
immunity to status moves—to serve as an
unflinching offensive pivot. With a Life Orb
or Choice Specs set, it fires off high-
powered STAB Make It Rain and Shadow Ball
while setting up Nasty Plot to break through
bulky cores. Its flexible Tera options in
Water and Steel let it flip match-ups on the
fly, and it slots naturally into balanced
squads alongside Incineroar, Archaludon and
Rillaboom that provide speed control, Fake
Out and terrain support.</OUTPUT>"
  },
  {
    "pokemon": "Gholdengo",
    "input": "Write the 'full_analysis'
section using only the data given.\n\n<DATA>
{\n\"Gholdengo\": {\n\"Abilities\":
{\n\"goodasgold\": 2150.0674341869494},
\n\"Items\": {\n\"lifeorb\":
0.40078689096573855, \n\"choicespecs\":
0.283475718438179}, \n\"Spreads\":
0.1762777004844856}, \n\"Moves\":
[\n\"makeitrain\", \n\"shadowball\",
\n\"nastyplot\", \n\"protect\"], \n\"Tera Types\":
{\n\"water\": 0.37287903306152614, \n\"steel\":
0.45402448761654873}, \n\"Teammates\":
[\n\"Incineroar\", \n\"Archaludon\",
\n\"Sneasler\", \n\"Rillaboom\", \n\"Dragonite\",
\n\"Ursaluna-Bloodmoon\"]}}</DATA>"
  }
]
```

BAB III: PEMODELAN

3.1 Arsitektur Model

Konstruksi dataset dalam penelitian ini diawali dengan proses augmentasi data menggunakan model Kimi-K2 0905, sebuah arsitektur *Mixture-of-Experts* (MoE) yang memiliki kapabilitas *agentic coding* serta jendela konteks (*context window*) luas hingga 256k token. Karakteristik ini memungkinkan model untuk melakukan penalaran mendalam terhadap hubungan sistemik yang kompleks antara komposisi tim Pokémon dan distribusi peran strategis masing-masing unit. Melalui metode ini, dihasilkan lebih dari 2.200 pasang data input-output sintetis yang terorganisir ke dalam delapan dimensi analisis struktural.

Implementasi data sintetis ini bertujuan untuk meningkatkan volume dataset sekaligus menjaga rigiditas kualitas informasi. Dengan mengonstruksi entri yang variatif namun tetap berbasis pada data empiris, dataset ini memberikan fleksibilitas tinggi bagi model dalam menangani tugas *Question Answering* (QA) dengan masukan pengguna yang beragam. Pendekatan ini memperkaya pola informasi (*pattern recognition*) dalam dataset, sehingga memungkinkan Small Language Model (SLM) untuk menginternalisasi logika pembentukan tim yang lebih adaptif dan sadar strategi (*strategy-aware*).

SLM yang kami latih adalah Phi-3-mini-Instruct-4K-bnb-4bit, yaitu instruction-tuned 3.8B model dengan 4000 token context dan 4-bit quantization. SLM kami juga didampingi dengan teknik RAG (Retrieval-Augmented Generation), dimana data original akan di-embed dengan *Embedding Gamma* dari Google dan disimpan dalam FAISS vector store. Ketika sebuah query dari user diterima, entry yang paling relevan akan ditarik dan dikirim ke fine-tuned Phi-3-mini model untuk menghasilkan rekomendasi strategi context-aware dengan data up-to-date.

3.2 Skenario Pelatihan

Metode pelatihan yang digunakan adalah Q-LoRA (Quantized-Low Rank Adapter) yang merupakan salah satu metode PEFT (Parameter-Efficient Fine Tuning). Q-LoRA menggunakan 4-bit Normal Float sebagai tipe data weight model. NF4 adalah tipe data yang menggunakan representasi 4-bit yang dikonversikan kembali menjadi 16-bit float ketika dihitung dengan 16 bin yang dibagi sesuai distribusi normal. Q-LoRA menggunakan double quantization yang mengurangi ukuran scaling factor quantization.

Q-LoRA mengasumsikan distribusi normal pada weight model, sehingga menghilangkan efek dari weight outlier (yang sangat besar dan sangat kecil). Riset selanjutnya menemukan bahwa weight outlier mempengaruhi kinerja model secara signifikan, sehingga ketiadaan weight outlier mengurangi kemampuan model dengan sangat signifikan. Maka dari itu, Q-LoRA menggunakan block-wise quantization, sehingga asumsi distribusi normal diaplikasikan hanya pada bin-bin yang sudah dibagi dari awal. Hal ini mencegah weight outlier tidak punya pengaruh, melainkan quantization NF4 hanya diaplikasikan pada setiap bin.

Q-LoRA yang digunakan dalam proses pelatihan memiliki hyperparameter sebagai berikut.


1. Rank: 16
2. Alpha: 16
3. Target layers: all
4. Gradient checkpointing: 'unsloth'
5. Bias: None
6. LoRA dropout: 0.0
7. Rank-Stabilized LoRA: false
8. LoftQ: None

Rank 16 digunakan karena nilai ini merupakan safe spot untuk resource efficient training dan performa model yang bagus. Sebagai komplemennya, alpha 16 digunakan agar semua weight dalam adapter memiliki efek. Semua layer dalam model diberikan adapter LoRA, sehingga efek LoRA ada pada setiap stage model. LoRA tidak diberikan dropout dan bias agar knowledge awal model tetap terjaga. Hyperparameter ke 7 dan 8 tidak digunakan karena Rank-Stabilized LoRA sifatnya experimental, dan model sudah quantized sehingga LoftQ tidak digunakan agar tidak terkuantisasi lagi. Hyperparameter model dijelaskan pada lampiran B.


3.3 Diagram Arsitektur

Phi-3 menggunakan arsitektur Transformer decoder-only, seperti GPT, tapi dioptimalkan secara agresif untuk membuatnya lebih efisien dan ringan tanpa kehilangan performa. Model ini memproses input teks melalui tahap tokenisasi dan embedding, yang kemudian diperkaya dengan Rotary Positional Embedding (RoPE) untuk mempertahankan

informasi urutan token secara efektif pada konteks panjang. Inti arsitektur Phi-3 terdiri dari sejumlah blok Transformer decoder berulang yang masing-masing mencakup pre-layer normalization, causal multi-head self-attention dengan mekanisme key-value caching, serta feed-forward network berbasis gated MLP seperti SwiGLU. Struktur ini memungkinkan model untuk menangkap dependensi jangka panjang dan melakukan representasi semantik yang kaya meskipun jumlah parameter relatif kecil. Dikarenakan sifat model architecture Phi-3 dirahasiakan, kami tidak dapat menemukan visualisasi diagram arsitektur model tersebut. Berikut diagram architecture dari pondasi model Phi-3, yaitu Transformer decoder-only architecture (Gambar 3.3.1) dan visualisasi perbandingan cara kerja QLoRA dengan fine-tuning biasa.



Gambar 3.3.1. Transformer Architecture



Gambar 3.3.2. Visualisasi Perbandingan QLoRA dengan Fine-tuning dan LoRA Fine-tuning

BAB IV: EVALUASI

4.1 Metric Evaluasi

Evaluasi model dilakukan melalui analisis struktur data Pokémon menggunakan metrik seperti Training Loss, BLEU dan *embedding similarity*. Untuk validasi kualitatif, penelitian ini menggunakan sejumlah sampel representatif sebagai titik acuan (*gold standards*) ideal yang mencakup parameter kualitas tim serta argumen logis mengenai efektivitas strategi. Kualitas tim tersebut dievaluasi berdasarkan distribusi peran setiap Pokémon serta sinergi strategis yang tercipta dari keseimbangan antara kekuatan ofensif dan cakupan pertahanan (*defensive coverage*).

Metric yang digunakan berupa training loss, dimana model kami mencapai ~ 0.7 dalam 4 epochs. Dalam 100 steps pertama, training loss menurun secara drastis dari 2.7 menjadi 1.2 (Lihat Gambar 4.3.a). Setelah fase awal tersebut, kurva menunjukkan tren penurunan yang stabil dan gradual. Hal ini merepresentasikan proses penyempurnaan (*fine-tuning*) yang stabil, di mana model mulai mempelajari hubungan semantik yang lebih kompleks dan nuansa strategis dalam meta-permainan VGC, tanpa menunjukkan tanda-tanda *overfitting* yang signifikan. Stabilitas penurunan ini mengonfirmasi bahwa data sintesis yang dibuat Kimi-K2 efektif dalam membantu model mencapai konvergensi yang optimal untuk tugas *question answering* yang bersifat *context-aware*.

4.2 Perbandingan Performa Model dengan kapabilitas RAG dan tanpa RAG


Kami menguji performa model dalam dua skenario: tanpa RAG dan dengan RAG. Hasil pengujian menunjukkan bahwa model cenderung mengalami halusinasi terutama pada dua aspek: nama *move* Pokémon dan tipe Pokémon.

Dengan menerapkan RAG, konteks dalam model menjadi lebih *grounded* pada fakta. Informasi relevan yang diinjeksi ke dalam konteks model meningkatkan akurasi output secara signifikan. Saat menggunakan query yang sama, pendekatan ini berhasil mengurangi halusinasi dan menghasilkan respons yang memenuhi standar kualitas yang diharapkan. Dampak ini terlihat pada seluruh output yang dihasilkan model.


Untuk menentukan jumlah dokumen yang digunakan sebagai konteks, dilakukan pengujian dengan variasi 1 sampai 7 dokumen. Hasil evaluasi menunjukkan bahwa penggunaan 5 dokumen memberikan tingkat akurasi tertinggi serta konteks yang paling

informatif bagi proses generasi (Gambar 4.3.b dan 4.3.c). Sebaliknya, penggunaan 1 dokumen menghasilkan tingkat halusinasi tertinggi akibat keterbatasan konteks, sebagaimana ditunjukkan pada Gambar 4.3.d Oleh karena itu, konfigurasi dengan 5 dokumen dipilih sebagai keseimbangan optimal antara kualitas konteks dan performa sistem.

4.3 Visualisasi Hasil




Gambar 4.3.a Plot Training Loss over 500 steps across 4 epochs.



Gambar 4.3.b. Keluaran model pada konfigurasi RAG dengan lima dokumen konteks, yang menunjukkan tim pokemon yang melebihi standar ideal.



Gambar 4.3.c. Representasi visual tim Pokémon dalam format yang disederhanakan untuk meningkatkan keterbacaan, dengan seluruh detail sesuai dengan Gambar 4.3.b.



Gambar 4.3.d Keluaran model pada konfigurasi RAG dengan satu dokumen konteks, yang menunjukkan keterbatasan informasi yang tersedia.

BAB V: IMPLEMENTASI

5.1. Implementasi Model dalam Aplikasi

Model *Small Language Model* (SLM) yang telah melalui proses *fine-tuning* diintegrasikan ke dalam *backend* berbasis Flask dan diimplementasikan pada aplikasi web berbasis Next.js yang dinamakan PokéGuide. Sistem ini menyediakan antarmuka percakapan yang memungkinkan pengguna untuk mengajukan permintaan rekomendasi *team-building* Pokémon. Setiap sesi percakapan baru memungkinkan pengguna memberikan masukan kontekstual, yang kemudian diproses oleh model untuk menghasilkan rekomendasi yang mempertimbangkan aspek statistik dan strategis permainan. Keluaran sistem disajikan dalam format terstruktur yang terdiri atas delapan komponen utama guna meningkatkan keterbacaan, konsistensi, dan *machine-readability* informasi.

5.2. Alur Kerja

User dapat menggunakan aplikasi ini dengan menekan tombol *New Chat* yang berada di panel kiri, tombol ini berfungsi untuk membuat conversation baru antara user dan chatbot PokéGuide. Lalu, user dapat berbincang bersama model dengan menaruh pertanyaan atau instruksi seperti: “Build me a team surrounding X”, dalam chat area. Lalu, setelah menekan tombol send, maka query akan dikirim ke backend untuk diproses. Dan output model akan disampaikan ke UI setelah proses generation selesai.

Sebelum proses generasi respons dilakukan, sistem terlebih dahulu melakukan klasifikasi intensi pengguna yang dikategorikan kedalam jadi dua, yaitu *general intent* dan *structured intent*. *General intent* mencakup pertanyaan umum terkait Pokémon tertentu dalam format kompetitif VGC Regulation H, seperti karakteristik, peran, atau interaksi antar *move*.

Pada dua skenario ini, sistem *Retrieval-Augmented Generation* (RAG) digunakan untuk mengambil data relevan dari basis pengetahuan eksternal sebagai konteks tambahan bagi model, dengan tujuan meningkatkan akurasi dan mengurangi potensi halusinasi. Sumber data yang digunakan juga disertakan dalam keluaran akhir sebagai bentuk transparansi dan *traceability* informasi.

Untuk *structured intent*, sistem memanfaatkan skema data eksplisit yang didefinisikan menggunakan Pydantic BaseModel guna memastikan konsistensi dan validitas keluaran model. Setiap Pokémon direpresentasikan sebagai sebuah *base class* yang mencakup atribut

utama, yaitu nama Pokémon, ability, item, moveset, serta EV spread. Selanjutnya, sebuah tim Pokémon direpresentasikan sebagai *base class* terpisah yang terdiri atas daftar objek Pokémon, sehingga membentuk struktur hierarkis yang terstandarisasi.

Model menghasilkan keluaran dalam format JSON yang sesuai dengan skema tersebut, yang kemudian diproses di sisi *frontend* menjadi representasi teks yang lebih mudah dipahami oleh pengguna. Selain itu, sistem secara otomatis mengambil *sprite* visual dari masing-masing Pokémon melalui antarmuka pemrograman aplikasi (API) eksternal dan menampilkannya pada panel antarmuka, sehingga meningkatkan keterpaduan antara representasi semantik dan visual dalam pengalaman pengguna.

BAB VI: REFLEKSI

6.1 Analisis Kritis

Penelitian ini berhasil mengembangkan PokéGuide, sebuah sistem berbasis Small Language Model yang dilatih secara khusus untuk memberikan rekomendasi team-building Pokémon dalam konteks kompetisi VGC Regulation H.

6.1.1 Efektivitas Fine-Tuning pada Dataset Sintetis

Fine-tuning Phi-3-mini pada dataset sintetis yang dihasilkan Kimi-K2 terbukti efektif dalam menghasilkan output terstruktur dan strategy-aware. Model mampu menghasilkan rekomendasi tim dengan distribusi peran yang jelas seperti offensive pivot, defensive wall, speed control, dan sweeper yang mencerminkan pemahaman terhadap mekanik VGC. Kurva training loss yang menurun dari 2.7 menjadi ~ 0.7 dalam 4 epoch menunjukkan konvergensi yang baik tanpa overfitting signifikan.

Kualitas data sintetis menjadi faktor krusial. Dengan memanfaatkan Kimi-K2 yang memiliki context window 256k token, dataset yang dihasilkan kaya akan konteks strategis dan mencakup nuansa seperti interaksi move, type matchup, dan sinergi antar-Pokémon. Hal ini mengurangi kebutuhan pelabelan manual dan memungkinkan model belajar dari pola reasoning yang kompleks.

6.1.2 Dampak Retrieval-Augmented Generation

Implementasi RAG memberikan peningkatan signifikan terhadap akurasi dan reliabilitas respons model. Sistem RAG dengan embedding Gamma dan FAISS vector store mampu menginjeksi konteks relevan yang mengurangi halusinasi. Evaluasi menunjukkan bahwa penggunaan 5 dokumen memberikan keseimbangan optimal antara kecukupan konteks dan efisiensi, menghasilkan respons paling akurat dengan tingkat halusinasi terendah.

6.1.3 Structured output

Model berhasil menghasilkan rekomendasi dalam format terstruktur yang mencakup delapan dimensi analisis. Penggunaan Pydantic BaseModel untuk validasi output memastikan konsistensi dengan atribut seperti nama Pokémon, ability, item, moveset, dan EV spread yang terstandarisasi.

6.2 Kendala dan Pembelajaran

6.2.1 Halusinasi pada Nama, Move dan Mekanisme Pokémon

Limitasi paling signifikan adalah kecenderungan model menghasilkan halusinasi, baik dengan maupun tanpa RAG. Halusinasi yang paling umum adalah nama pokemon yang minor, seperti menambahkan kata setelah nama pokemon yang valid, contohnya “Whimsicott Whimsy” dan “Incineroar Incineroar”. Lebih parah lagi, munculnya nama move yang tidak valid namun memiliki kemiripan semantik dengan move yang sah, seperti "Dragonhammer" (kemungkinan konfusi antara "Dragon Hammer" atau kombinasi "Dragon" + "Hammer Arm") dan "Dry Skin" (sebenarnya adalah ability, bukan move). Model juga kerap merekomendasikan move Protect pada Pokémon yang secara mekanik tidak dapat mempelajarinya.

Context Window sebagai Sumber Halusinasi

Salah satu faktor krusial di balik halusinasi adalah keterbatasan 4K context window pada Phi-3-mini-Instruct. Meskipun sistem RAG mengambil 5 dokumen relevan, tidak semua konteks yang di-retrieve dapat dimasukkan jika total token melebihi batas 4K. Lebih problematis lagi, model harus menyisakan ~1.5K token context window untuk generation output sehingga konteks faktual yang dapat diinjeksi berkurang menjadi hanya ~2.5K token.

Ketika konteks dari 5 dokumen terpotong atau harus diringkas untuk memenuhi batasan ini, informasi krusial seperti moveset, ability, atau batasan mekanik tertentu mungkin hilang. Model kemudian harus bergantung pada pengetahuan parametrik yang telah dipelajari selama training, yang tidak selalu akurat untuk detail faktual seperti move pool setiap Pokémon. Ini menjelaskan mengapa halusinasi tetap terjadi meskipun RAG telah diimplementasikan, konteks yang di-retrieve tidak selalu dapat dimanfaatkan sepenuhnya karena keterbatasan kapasitas.

Kesalahan seperti ini tidak hanya menurunkan akurasi teknis, tetapi juga dapat menyesatkan pengguna pemula yang mengandalkan sistem untuk panduan strategis. RAG membantu mengurangi masalah ini, namun tidak mengeliminasi sepenuhnya karena keterbatasan struktural dalam arsitektur model.

6.2.2 Keterbatasan Evaluasi

Evaluasi yang dilakukan terutama bergantung pada metrik kuantitatif seperti training loss, BLEU score, dan embedding similarity. Namun, metrik ini tidak sepenuhnya menangkap kualitas strategis dalam konteks real-world gameplay. Training loss rendah menunjukkan model memprediksi training set dengan baik, tetapi tidak menjamin efektivitas strategi dalam pertandingan sebenarnya.

Evaluasi ideal memerlukan expert review dari pemain VGC berpengalaman atau testing dalam turnamen simulasi untuk menilai apakah tim yang direkomendasikan benar-benar viable dan kompetitif.

6.2.3 Keterbatasan Dataset dan Dinamika Meta

Dataset terbatas pada snapshot meta VGC Regulation H pada periode tertentu. Meta kompetitif Pokémon bersifat dinamis dan berubah seiring patch dan evolusi strategi komunitas. Model yang dilatih pada data statis akan mengalami penurunan relevansi seiring waktu jika tidak diperbarui secara berkala.

Dataset sintesis dari Kimi-K2, meskipun berkualitas tinggi, masih bergantung pada kualitas prompt engineering dan potensi bias dalam model pembangkitnya.

6.2.4 Validasi Real-World

Evaluasi pada held-out test set yang mencerminkan distribusi real-world query sangat diperlukan. Expert review dari pemain VGC profesional dapat memberikan feedback kualitatif mengenai viability strategi yang dihasilkan. Idealnya, sistem dapat diuji dalam turnamen simulasi atau diintegrasikan dengan battle simulator untuk mengukur win rate tim yang direkomendasikan.

6.2.5 Rencana Kedepannya untuk Mitigasi Halusinasi

Beberapa strategi dapat diimplementasikan untuk mengurangi halusinasi di eksperimen selanjutnya:

Post-processing validation

Menambahkan rules untuk memvalidasi output terhadap database learnset resmi sebelum ditampilkan kepada pengguna. Jika model merekomendasikan move yang tidak valid, sistem dapat menyaringnya secara otomatis.

Constrained prompt engineering

Membatasi nama move hanya pada daftar move yang valid, yang dimasukkan ke dalam konteks model dalam system prompt.

Ekspansi dataset

Menambahkan contoh negatif yang secara eksplisit menunjukkan move yang tidak dapat dipelajari oleh Pokémon tertentu.

6.2.6 Konklusi

Pipeline fine-tuning yang dikembangkan dengan penggunaan data sintesis berkualitas tinggi dari model MoE besar, kombinasi dengan RAG, dan structured output validation dapat diadaptasi untuk domain lain dengan karakteristik serupa: trading card games lain, strategy games, atau aplikasi seperti portfolio optimization dan treatment planning. Kualitas dataset sintesis dan desain schema output akan menjadi faktor penentu kesuksesan adaptasi.

PokéGuide mendemonstrasikan bahwa Small Language Models dapat di-fine-tune secara efektif untuk tugas domain-specific yang kompleks seperti team-building kompetitif Pokémon. Model berhasil menghasilkan rekomendasi terstruktur dan strategy-aware dengan pemahaman baik terhadap distribusi peran tim dan sinergi strategis.

Selain itu, metode evaluasi yang lebih robust dan kuantitatif juga perlu dikembangkan, seperti benchmark yang cocok untuk mengukur sinergi tim kompetitif pokémon dalam setiap format VGC. Topik ini dapat menjadi penelitian sendiri, yang dapat membuat hasil model fine-tuning lebih terarah dan terukur.

Dengan perbaikan yang direkomendasikan, PokéGuide berpotensi menjadi alat berharga bagi pemain Pokémon dan sebagai case study untuk AI-assisted decision making dalam domain permainan strategis yang kompleks.


Penelitian ini berkontribusi pada pemahaman tentang bagaimana SLM dapat diadaptasi untuk domain khusus dengan efisien, dan memberikan blueprint metodologis yang dapat diterapkan pada berbagai aplikasi yang memerlukan kombinasi knowledge retrieval, strategic reasoning, dan structured output generation.

REFERENSI


- Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. <https://arxiv.org/abs/2305.14314>
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., ... & Wang, H. (2023). Retrieval-augmented generation for large language models: A survey. <https://arxiv.org/abs/2312.10997>
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., ... & Chen, W. (2021). LoRA: Low-rank adaptation of large language models <https://arxiv.org/abs/2106.09685>
- Abdin, M., Jacobs, S. A., Awan, A. A., Aneja, J., Awadallah, A., Awadalla, H., ... & Zhou, X. (2024). Phi-3 technical report: A highly capable language model locally on your phone. <https://arxiv.org/abs/2404.14219>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459-9474.
- Hu, B., Huang, C., Zhang, P., Gao, X., Chen, Y., Liu, Z., & Sun, M. (2024). PokéLLMon: A grounding and reasoning benchmark for large language models in Pokémon battles. <https://arxiv.org/abs/2402.01118>
- Karten, S., Nguyen, A. L., & Jin, C. (2025). PokéChamp: An expert-level minimax language agent. <https://arxiv.org/abs/2503.04094>
- Yashwanth, T., & Dhatri, C. (2025). Reasoning under pressure: LLMs in competitive Pokémon battles. In *NeurIPS 2025 Workshop on Bridging Language, Agent, and World Models for Reasoning and Planning (LAW 2025)*.

LAMPIRAN


Screenshot Aplikasi



Output (general QnA with RAG)



Output (Structured output with RAG)



Link Proyek

Github: <https://github.com/StamleyJo-37/pokeguide>

Video Demo: [Video Demo](#)

Video Presentasi: [Video Presentasi.mp4](#)

Lampiran A: Glossary Istilah Penting

Istilah Pokémon VGC

- **VGC (Video Game Championships):** Format turnamen resmi Pokémon dengan sistem Doubles Battle
- **Doubles Battle:** Format pertarungan di mana setiap pemain mengoperasikan 2 Pokémon secara bersamaan
- **Synergy:** Kesesuaian dan saling melengkapi antar Pokémon dalam satu tim
- **Coverage:** Kemampuan tim untuk menghadapi berbagai tipe ancaman
- **Meta:** Strategi dan komposisi tim yang dominan dalam periode tertentu

Istilah Machine Learning

- **SLM (Small Language Model):** Model bahasa berukuran kecil (<10B parameter)
- **PEFT (Parameter-Efficient Fine-Tuning):** Metode fine-tuning yang hanya melatih sebagian kecil parameter
- **QLoRA:** Quantized LoRA - LoRA dengan kuantisasi 4-bit untuk efisiensi memori
- **RAG (Retrieval-Augmented Generation):** Teknik menggabungkan retrieval dan generasi
- **NF4 (Normal Float 4):** Tipe data 4-bit dengan asumsi distribusi normal

Lampiran B: Spesifikasi Model

Model Base: Phi-3-mini-4k-instruct

- Jumlah Parameter: 3.8B
- Context Length: 4,096 token
- Architecture: Transformer decoder

Konfigurasi QLoRA

- Rank (r): 8
- Alpha: 16
- Dropout: 0.05
- Target Modules: q_proj, v_proj, k_proj, o_proj
- Quantization: NF4 dengan double quantization

Hyperparameters

Parameter	Nilai
Per Device Batch Size	2
Gradient Accumulation Steps	8
Effective Batch Size	16 (2 × 8)
Warmup Steps	50

Max Steps	500
Learning Rate	3e-4
Optimizer	AdamW (8-bit)
Weight Decay	0.01
LR Scheduler	Linear
Max Sequence Length	2048
Precision	BF16/FP16
Gradient Checkpointing	Ya
Seed	3407

Lampiran D: Sumber Data

1. Smogon Strategy Dex (raw data)

Meta game list

<https://www.smogon.com/stats/2025-11/gen9vgc2025regh-1760.txt>

Leads & usage statistics

<https://www.smogon.com/stats/2025-11/leads/gen9vgc2025regh-1760.txt>

2. PokeAPI (pokemon sprites)

<https://pokeapi.co/>